

ViMamba-SER: Nhận dạng cảm xúc giọng nói tiếng Việt sử dụng kiến trúc Mamba và chiến lược tăng cường văn bản

Quang Huy Ngo (SE190631), Tan Dat Vo (SE190008), and Ly Huynh Khanh (SE193800)

Faculty of Artificial Intelligence, FPT University, Lo E2a-7, Street D1, High-Tech Park, Long Thanh My Ward, Thu Duc City, Ho Chi Minh City, Vietnam.
{ngoquanghuy2k5, votandat31082005}@gmail.com

Abstract. Nhận dạng cảm xúc qua giọng nói (Speech Emotion Recognition - SER) là bài toán có tính ứng dụng cao nhưng đối mặt với nhiều thách thức khi xử lý tiếng Việt, một ngôn ngữ đa thanh điệu nơi âm điệu vừa mang chức năng từ vựng vừa chứa đựng thông tin cảm xúc. Trong đề xuất này, chúng tôi giới thiệu ViMamba-SER, một cách tiếp cận mới kết hợp đặc trưng âm thanh và văn bản. Thay vì sử dụng kiến trúc Transformer với chi phí tính toán bậc hai $O(n^2)$, nghiên cứu ứng dụng mô hình không gian trạng thái Mamba (độ phức tạp tuyến tính $O(n)$) để xử lý hiệu quả các chuỗi tín hiệu âm thanh dài. Hướng tiếp cận đa phương thức này kỳ vọng sẽ giải quyết được các hạn chế của hệ thống đơn phương thức hiện hành và thiết lập một mốc đánh giá mới cho bài toán SER tiếng Việt.

Keywords: Speech Emotion Recognition · Mamba · Vietnamese · Bimodal Fusion · Text Enhancement

1 Giới thiệu

Nhận dạng cảm xúc giọng nói đóng vai trò then chốt trong việc phát triển các hệ thống thông minh như chăm sóc khách hàng tự động, hỗ trợ tâm lý hay giao diện người-máy. Phần lớn các nghiên cứu hiện nay chủ yếu tập trung vào tiếng Anh hoặc tiếng Trung. Trong khi đó, tiếng Việt có sáu thanh điệu với các đặc trưng ngữ điệu rất phức tạp. Thanh điệu trong tiếng Việt không chỉ thay đổi nghĩa của từ mà còn biến thiên mạnh theo trạng thái tâm lý người nói, khiến các mô hình huấn luyện trên tiếng Anh khó có thể chuyển tiếp hiệu quả.

Về mặt giải pháp kỹ thuật, Transformer đang là tiêu chuẩn chung. Tuy nhiên, kiến trúc này bộc lộ điểm yếu về tài nguyên tính toán do cơ chế tự chú ý có độ phức tạp $O(n^2)$, đặc biệt kém hiệu quả khi xử lý tín hiệu âm thanh thô kéo dài hàng nghìn khung hình. Để khắc phục, chúng tôi đề xuất sử dụng kiến trúc Mamba có khả năng tính toán tuyến tính $O(n)$. Gần đây, các biến thể của Mamba đã cho thấy khả năng giảm đáng kể lượng phép toán mà vẫn vượt trội hơn Transformer trong các tác vụ phân tích cảm xúc. Việc áp dụng Mamba là lựa chọn tối ưu cho các hệ thống bị giới hạn về phần cứng tính toán.

Hơn nữa, phân tích cảm xúc chỉ dựa trên âm thanh thường bỏ sót các sắc thái ngữ nghĩa quan trọng. Nghiên cứu này kết hợp thêm kênh văn bản được trích xuất tự động qua mô hình PhoWhisper. Sự kết hợp giữa đặc trưng ngữ điệu từ giọng nói và đặc trưng ngữ nghĩa từ văn bản tạo ra một quy trình phân tích toàn diện hơn.

2 Định nghĩa bài toán và Mục tiêu nghiên cứu

2.1 Định nghĩa bài toán

Đầu vào là một đoạn tín hiệu âm thanh chứa giọng nói tiếng Việt với thời lượng từ 1 đến 10 giây. Hệ thống có nhiệm vụ dự đoán và phân loại trạng thái cảm xúc của người nói vào một trong năm nhãn cơ bản: Vui (Happy), Buồn (Sad), Giận (Angry), Lo lắng (Anxious) và Trung tính (Neutral).

2.2 Mục tiêu nghiên cứu

Đề tài hướng tới bốn mục tiêu cụ thể:

- **Nâng cao độ chính xác:** Xây dựng hệ thống đạt độ chính xác vượt qua mức cơ sở hiện hành (89% trên tập dữ liệu VNEMOS) thông qua kiến trúc kết hợp Mamba.
- **Kiểm chứng chiến lược Text-enhancement:** Đánh giá định lượng mức độ cải thiện hiệu suất khi sử dụng văn bản làm dữ liệu bổ trợ so với việc chỉ dùng đơn thuần tín hiệu âm thanh.
- **So sánh cơ chế Fusion:** Đối chiếu hiệu quả của mạng Mamba với các phương pháp kết hợp đặc trưng truyền thống.
- **Đánh giá tác động của ngôn ngữ:** Phân tích ảnh hưởng cụ thể của hệ thống thanh điệu tiếng Việt đối với kết quả nhận dạng cảm xúc.

3 Các nghiên cứu liên quan và Khoảng trống nghiên cứu

3.1 Các nghiên cứu liên quan

Nhận dạng cảm xúc tiếng Việt: Việc xây dựng các hệ thống phân tích cảm xúc riêng cho tiếng Việt đang ngày càng được chú ý. Sự xuất hiện của tập dữ liệu VNEMOS đã cung cấp một chuẩn đối sánh quan trọng cho các thử nghiệm. Một số nghiên cứu hiện đại đã thử nghiệm kết hợp HuBERT (cho nhánh âm thanh) và PhoBERT (cho nhánh văn bản) thông qua cơ chế gộp trọng số độ tin cậy và cho thấy ưu điểm vượt trội của hướng tiếp cận đa phương thức.

Kiến trúc Mamba trong xử lý tiếng nói: Sự ra đời của mô hình không gian trạng thái Mamba đã giải quyết điểm yếu về bộ nhớ của Transformer. Gần đây nhất, nghiên cứu TF-Mamba (2025) đã tiên phong áp dụng Mamba cho tác vụ phân tích cảm xúc đa phương thức trên tiếng Anh. Bằng cách lấy văn bản làm trung tâm để căn chỉnh và làm giàu đặc trưng âm thanh, mô hình này không chỉ giảm thiểu đáng kể khối lượng tính toán mà còn duy trì độ chính xác cao.

3.2 Khoảng trống nghiên cứu (Research Gaps)

Dựa trên việc khảo sát các mô hình hiện tại, nghiên cứu này được thiết kế để lấp đầy các khoảng trống học thuật sau:

1. **Chưa có kiến trúc Mamba-fusion cho ngôn ngữ thanh điệu:** Các nghiên cứu áp dụng Mamba cho dữ liệu âm thanh hiện mới dừng lại ở tiếng Anh. Đề tài là nỗ lực đầu tiên tùy biến và thử nghiệm kiến trúc này trên hệ thống đa thanh điệu phức tạp của tiếng Việt.
2. **Thiếu sự kết hợp đa phương thức cho tiếng Việt:** Phần lớn các hệ thống hiện nay chỉ phân tích sóng âm. Bằng cách sử dụng WavLM kết hợp cùng PhoBERT-v2, đề tài cung cấp một quy trình kết hợp có khả năng bù đắp thông tin chéo giữa hai kênh.
3. **Cải tiến các mô hình cơ sở:** Hệ thống tích hợp trực tiếp các mô hình nền tảng hiện đại, giúp hoạt động ổn định hơn với nhiều môi trường so với các bộ trích xuất đặc trưng thế hệ cũ.

4 Dữ liệu và Kiến trúc đề xuất

4.1 Dữ liệu nghiên cứu sơ bộ

Để giải quyết bài toán cho tiếng Việt, nghiên cứu sẽ sử dụng VNEMOS, một tập dữ liệu chuyên biệt về cảm xúc giọng nói được thu thập từ các tác phẩm điện ảnh và chương trình truyền hình. Mặc dù tập dữ liệu này phản ánh được sự đa dạng về ngữ điệu và sắc thái tự nhiên, kích thước của nó tương đối khiêm tốn. Do đó, hệ thống của chúng tôi tận dụng sức mạnh của các mô hình cơ sở đã được huấn luyện trước như WavLM, PhoWhisper và PhoBERT để bù đắp giới hạn về lượng dữ liệu, qua đó tập trung tài nguyên tính toán vào việc tinh chỉnh khối kết hợp.

4.2 Tổng quan kiến trúc ViMamba-SER

Kiến trúc đề xuất được thiết kế nhằm khai thác tối đa luồng thông tin song song từ âm thanh và văn bản. Hình 1 minh họa quy trình hoạt động tổng thể của hệ thống.

Hệ thống bao gồm ba thành phần chính. Thành phần thứ nhất là bộ trích xuất đặc trưng, trong đó tín hiệu âm thanh thô được đưa qua WavLM để lấy biểu diễn âm học. Đồng thời, âm thanh được chuyển tự động thành văn bản qua PhoWhisper và mã hóa ngữ nghĩa bởi PhoBERT-v2.

Thành phần thứ hai là module tăng cường văn bản (TME), có nhiệm vụ căn chỉnh chuỗi thời gian giữa hai phương thức và sử dụng độ tương đồng cosine để làm giàu đặc trưng âm thanh dựa trên ngữ cảnh văn bản.

Thành phần cuối cùng là mạng kết hợp Mamba, nơi các khối Mamba hai chiều lập mô hình phụ thuộc ngữ cảnh chéo, giúp tổng hợp thông tin từ cả hai nguồn một cách hiệu quả trước khi đưa qua lớp phân loại để dự đoán nhãn cảm xúc cuối cùng.




Fig. 1. Sơ đồ chi tiết kiến trúc ViMamba-SER. Hệ thống được chia làm hai giai đoạn chính: Trích xuất đặc trưng từ luồng âm thanh/văn bản và Kết hợp đa phương thức sử dụng mạng Mamba.